

作业: 负责任人工智能导论

负责任人工智能: 原则、治理与量化方法

黄斐, 新南威尔士大学

Table of contents

概述	1
说明	1
问题	1
问题一 — 负责任人工智能生命周期	1
问题二 — 三大支柱的应用	2
问题三 — 监管路径比较 (中国)	2
问题四 — 反思	2

概述

本作业要求你将第一章介绍的负责任人工智能生命周期、六项人工智能伦理原则以及比较监管格局, 应用于你自行选择的一个人工智能应用场景。

说明

在开始作答前, 请先选择一个你个人比较熟悉的人工智能应用场景, 最好与你自己的专业或工作 (无论是现在还是过去) 密切相关。例如, 如果你从事保险行业, 可以选择理赔欺诈检测模型; 如果你从事人力资源工作, 可以选择简历筛选工具; 如果你从事信贷相关工作, 可以选择信用审批模型; 如果你从事医疗相关工作, 可以选择分诊辅助工具。请选择一个课堂讲授中未曾讨论过的场景, 这样你才是在运用课堂所学的概念, 而不是简单复述。在以下四道题目中, 请始终使用同一个应用场景。

本作业不设字数限制。请针对每道题目的具体要求作答, 篇幅长短视回答问题所需而定。几句论证清晰的话, 胜过一段观点单薄却篇幅冗长的文字。整份作业设计为约两小时可以完成。

请确保你的答案让一个来自不同专业背景、对你所选领域并不熟悉的同学也能读懂。如果使用了你所在专业特有的术语, 请在第一次使用时用通俗的语言简要解释。

问题

问题一 — 负责任人工智能生命周期

- 针对你所选择的应用场景, 逐一说明课堂讲授中介绍的六个阶段的生命周期 (问题定义、数据收集、探索性数据分析、建模、评估、部署)。针对每个阶段, 写下一个项目团队在该阶段应当思考的具体伦理问题。课堂讲义中每个阶段的示例问题表格展示了这里所期望的问题类型。
- 假设在部署数月之后, 一次审计发现你的系统在两个人口统计群体之间的结果存在差异, 而这一差异在开发阶段并未显现。例如, 其中一个群体获得不利结果的比率明显更高, 而这一差异与真实的风险或个人条件无关。这类差异正是一项核心的公平性问题: 它意味着系统并未在不同群体之间, 对条件相当的个体给予一致的对等。你认为生命周期中的哪一个阶段最有可能是造成这一差异的根本原因? 为什么?

问题二 — 三大支柱的应用

请从本课程的三大支柱（公平性与非歧视、透明度与可解释性、隐私与数据伦理）中选择两项。

- a. 说明每项原则如何具体适用于你所选择的应用场景。
- b. 请参照课堂讲授中“车载远程信息保险公司”案例的思路, 描述一个合理的情境, 在该情境中满足你所选两大支柱中的一项会使满足另一项更加困难。说明这种张力的根源。

问题三 — 监管路径比较 (中国)

请阅读并比较课堂讲授中提及的两项中国监管文件: 国家金融监督管理总局发布的《关于银行业保险业人工智能安全开发应用的指导意见》(金发〔2026〕8号, 以下简称《银行业保险业人工智能指导意见》), 以及《个人信息保护法》第24条。

- a. 概述每一项所施加的核心义务。
- b. 假设你在问题一中所选择应用场景中的机构, 同时也在中国运营, 或处理中国境内个人的个人信息。这两项监管文件是否会分别适用于该机构? 请结合每项文件的适用范围 (例如所覆盖的行业, 或所保护的对象的个人信息) 说明理由。对于适用的那一项 (或那几项), 请具体说明遵守该要求将使你的机构需要采取哪些做法。

问题四 — 反思

课堂讲授指出, “负责任人工智能是一项职业责任, 而不仅仅是一项技术责任。” 请设想, 在你于问题一中所选择的应用场景里, 谁会是对模型输出负责的领域专业人士, 而非构建模型的数据科学家或工程师 (例如, 若你的应用场景属于保险领域, 可以是精算师; 若属于信贷领域, 可以是信用风险分析师; 若属于招聘领域, 可以是人力资源分析主管)。

- a. 请描述这位专业人士在六阶段生命周期 (即问题一中的六个阶段) 中, 于两个不同阶段可以采取的两项确实不同的具体行动, 以践行这一责任。
- b. 针对每一项行动, 请具体说明为何正是这位专业人士的角色, 而非数据科学家或工程师的角色, 赋予了他们采取该行动的地位或权限。
- c. 针对这两个阶段, 请分别简要说明: 如果只有数据科学家或工程师参与、而没有这位专业人士的介入, 该阶段很可能会呈现出怎样的情况。