

负责任人工智能导论·第一次作业

姓名：林富强 专业：软件工程

所选应用场景：软件缺陷预测系统

我选择的场景是一个“软件缺陷预测系统”：一家软件公司构建机器学习模型，根据代码仓库的提交记录、代码度量（如代码行数、圈复杂度）、历史缺陷数据以及开发者的行为特征（如提交时间、提交频率），预测某次代码变更或某个模块在未来出现缺陷（bug）的概率，并据此决定哪些变更需要额外的人工评审、加长测试或推迟发布。

说明：代码度量指从源代码自动计算出的数值特征，例如代码行数、分支复杂度，用于衡量代码的规模与结构复杂程度；“提交”指开发者将一次代码修改保存到版本库中的操作。该系统属于软件工程领域的常见应用，课堂讲授中未讨论过该场景。

问题一：负责任人工智能生命周期

a. 六阶段生命周期及每阶段的伦理问题：（1）问题定义：系统的目标变量“是否缺陷”应当如何界定？以历史 bug 报告为准还是以测试失败为准？优化目标是否只追求预测准确率，还是要兼顾公平性、透明度与监管要求？谁拥有该系统的使用、监督与风险的所有权？（2）数据收集：收集开发者个人行为数据（提交时间、提交频率）是否侵犯隐私？代理变量（如“深夜提交占比”“连续加班天数”）是否间接编码了受保护属性（年龄、性别、家庭责任）？历史缺陷数据是否反映了对特定团队或开发者既有偏见？（3）探索性数据分析：哪些输入特征可能直接或通过与受保护群体的相关性产生歧视性影响？每一个特征（如代码行数、提交时段）能否向监管者、被评估的开发者而非仅向内部团队解释？（4）建模：模型是否在准确性与公平性、可解释性之间取得平衡？能否评估输出结果在不同团队、不同资历、不同工作模式的开发者之间是否存在差异？可解释程度是否足以支撑审计？（5）评估：模型表现是否在相关子群体中同样成立，而不仅仅在总体层面成立（例如按团队、按资历分层查看精确率与召回率）？结果能否泛化到新的项目与新的代码风格？公平性—准确性的权衡取舍是否已向决策者充分说明？（6）部署：模型上线后是否定期接受审计（如按团队、按资历监控结果分布）？被标记为高缺陷风险的开发者能否申诉或质疑该结果？是否存在反馈回路，将上线后的结果用于改进未来的迭代？

b. 部署后出现群体差异，最可能的根本原因：最有可能的根本原因是**评估（Evaluation）阶段**。开发阶段通常以总体指标（总体精确率、总体 AUC 等）判断模型好坏，若只在总体层面评估，群体间的差异会被总体均值掩盖：模型在整体上表现良好，但在某个子群体（如按团队、资历或工作模式划分的群体）中却存在系统性偏差。这与课堂生命周期表中评估阶段的关键伦理问题——“模型表现是否在相关子群体中同样成立，而不仅仅是在总体层面成立”——完全对应：开发时若未做子群体分层评估，差异自然要到部署后审计按群体拆解时才暴露。当然，差异的“种子”往往更早在数据收集（代理变量混入）或问题定义（目标变量界定不当）阶段就已埋下，但使其在开发阶段未被发现的直接原因，是评估阶段缺少子群体维度的分解检查。因此，修正措施应同时包含：评估阶段强制做子群体分层评估并设定公平性阈值，以及回溯审计上游的代理变量。

问题二：三大支柱的应用（选取公平性与非歧视、隐私与数据伦理）

a. 每项原则如何具体适用于本场景：（1）公平性与非歧视：缺陷预测系统会直接影响开发者的工作负荷与职业评价——被标为高风险的变更会被要求额外评审、返工甚至推迟发布。若模型使用“深夜提

交”“提交频率”“连续加班”等行为特征，而这些特征与年龄、性别、是否承担家庭责任等受保护属性相关，就会形成代理歧视：即使模型未直接使用受保护属性，仍可能对承担更多家庭责任、只能夜间写代码的开发者系统性给出更高的缺陷预测，从而在团队内部造成不公平的负担分配。（2）隐私与数据伦理：系统收集开发者个人数据——提交时间戳（可推断作息与加班）、提交频率（可推断工作强度）、代码作者身份等。这些数据是否以明确的、实质性同意为前提？收集目的（缺陷预测）与使用目的（如绩效评估、人力规划）是否一致？是否与第三方共享？开发者能否要求删除自己的数据？若公司通过手机/IDE

插件持续采集开发者行为，其隐私风险与课堂车载远程信息保险公司案例中持续采集GPS位置数据的问题同构。

b. 满足一项使满足另一项更困难的情境：情境：为改善公平性，团队希望开展“差异影响分析”，即按受保护属性（如性别、年龄）统计各群体获得高风险标记的比例，从而发现并修正代理歧视。这要求系统在训练与审计时**收集并保留受保护属性数据**，才能度量“模型输出是否与这些属性相关”。张力：这恰恰与隐私原则冲突——隐私原则要求数据最小化（只收集实现目的所必需的数据）与目的的限制（不得收集与业务目的无关的敏感属性）。收集性别、年龄等敏感属性用于公平性审计，本身就在扩大个人数据的收集范围，增加泄露与滥用风险；若审计完成后未及时删除，还会违反留存最小化。张力根源：公平性审计“需要敏感属性作为测量输入”，而隐私保护“禁止收集不必要的敏感属性”——两者在数据收集环节存在结构性矛盾。这正是课堂中公平性与隐私两大支柱相互作用、需要权衡的体现：机构必须在“收集足够信息以证明公平”与“尽量少收集以保护隐私”之间作出有据可依的设计选择，例如采用差分隐私聚合统计或合成数据来度量群体差异，而不直接留存个体敏感属性。

问题三：监管路径比较（中国）

a. 两项监管文件的核心义务：（1）《银行业保险业人工智能安全开发应用的指导意见》（金发〔2026〕8号）：由中国国家金融监督管理总局发布，直接适用于银行与保险机构。核心义务包括：对人工智能应用进行风险分类，高风险应用须经审批；对高风险应用实施人工监督；保证透明度与可解释性；避免算法歧视等公平性问题；落实数据与网络安全保护；对外部引入的生成式人工智能模型设置程序性要求（评估、备案、使用规范等）。（2）《个人信息保护法》第24条：属于通用性法律，适用于所有在中国境内处理个人信息的机构。核心义务包括：自动化决策应当透明、结果公平；不得在交易价格等交易条件上对个人实行不合理的差别待遇（针对“大数据杀熟”）；个人有权要求说明自动化决策的依据（解释权）；对个人权益有重大影响的自动化决策，个人有权拒绝仅通过自动化方式作出决定。

b. 是否适用于所选场景机构：（1）金发〔2026〕8号：**不直接适用**。该指导意见的适用范围是“银行业保险业”机构。我的场景是一家软件公司构建内部缺陷预测系统，不是银行或保险公司，不落入该文件的直接监管范围。（2）《个人信息保护法》第24条：**适用**。该法规范的是在中国境内处理个人信息的任何机构，保护对象是“个人信息”而非特定行业。本场景的系统处理开发者个人数据（提交时间、行为特征），且公司在中国境内运营，因此受其约束。具体合规做法包括：向开发者告知系统的存在、目的与处理方式（透明）；上线前与上线后定期验证结果公平（结果公平）；对开发者的高风险标记提供解释说明（解释权）；若该标记影响开发者的绩效、晋升等重大权益，须为开发者提供非自动化的复核或申诉渠道，不得仅凭系统决定（拒绝纯自动化决策权）。结论：两项文件并非二选一，而是并行适用——金发8号以“机构类型”划界（银行保险机构才适用），个保法24条以“是否处理个人信息”划界（处理中国境内个人信息的任何机构均适用）。我的软件公司场景落入个保法24条的适用范围，而不落入金发8号。

问题四：反思——负责任AI是职业责任而非仅技术责任

所选领域专业人士：在软件缺陷预测场景中，对模型输出负责的领域专业人士是**软件质量保障负责人（QA 经理）或工程负责人（Engineering Manager）**，而非构建模型的数据科学家或工程师。他们负责判断代码变更能否发布、缺陷风险如何分级、对开发者工作安排与产品质量负有最终责任。

a. 该专业人士在两个阶段的两项不同行动：行动一（问题定义阶段）：工程负责人与 QA 经理在项目启动时定义“缺陷”的业务含义与风险分级标准——确定哪些变更需要额外评审、高风险标记将如何影响发布决策，并明确该系统不得用于绩效评估或人事决策的边界。他们把公平性要求（不得让特定群体承担不成比例的风险标记）写入需求与验收标准。行动二（部署阶段）：QA

经理在系统上线后建立“申诉复核”机制——当开发者对被标记为高风险的变更提出异议时，由 QA 团队人工复核；同时定期审查按团队、资历划分的高风险标记分布，发现群体差异趋势时要求模型团队修正或回滚。

b. 为什么是这位专业人士而非数据科学家：行动一：定义业务目标、风险容忍度与系统边界属于业务与质量责任，QA/工程负责人被组织授权决定“什么可以发布、如何分级”，数据科学家只有在其设定的目标下优化模型，无权单方面定义高风险的标准或禁止将系统用于绩效评估。行动二：QA 经理拥有发布放行权与质量一票否决权，这是其岗位赋予的地位；而数据科学家缺乏中止上线、驳回模型结果的权限。对系统造成的业务与人事后果承担责任的是质量负责人，因此只有他们具备发起申诉复核与回滚的权威。

c. 若只有数据科学家/工程师参与时的情形：问题定义阶段：很可能只把“缺陷”简单定义为“历史上出现过 bug 的模块”，目标设为最大化预测准确率，忽略公平性、可解释性与监管约束，最终得到一个“技术上很准、伦理上失控”的模型——正如课堂所指出的，失败往往源于问题建构本身。部署阶段：很可能无人建立申诉复核渠道，高风险标记直接作用于开发者，群体差异出现时也无人在有权叫停；系统成为 ASIC REP 798 所描述的“黑箱”——没有治理、没有监测、没有问责。这也印证了“负责任AI是职业责任，而不仅仅是技术责任”：缺少拥有业务权威的专业人士介入，生命周期两端（定义与部署）都会出现责任真空。