

作业: 公平性原则

负责任人工智能: 原则、治理与量化方法

黄斐, 新南威尔士大学

Table of contents

概述	1
说明	1
问题	1
问题一	1
问题二	2
问题三	2
问题四	3

概述

本作业考察你对第二章公平性框架前两步的理解: 界定公平性、设计公平模型。第三、四步 (评估下游影响、审计系统) 在本章中仅作为选读的补充内容, 不在本作业考核范围内。问题一设定于一个自动化招聘筛选情境; 问题二至三则统一以保险公司的车险定价模型为情境展开。三道题目均综合了单项选择、配对、计算与简答题。问题四为一道简短的开放式写作题, 要求你将本章内容综合运用, 提出建议。

说明

问题一至三请为每一小题选出最佳答案, 并在题目要求处补充简短的文字说明理由。问题四请用你自己的语言撰写一份简短备忘录。整份作业预计耗时约 2 小时。

问题

问题一

一家在线招聘平台为回应一起歧视投诉, 从其候选人排序算法中移除了宗教信仰变量, 但保留了“申请人是否标明可接受周末排班”与“申请人申请休假的公共假期”这两项变量, 而这两者在训练数据中与宗教信仰相关。

- 这一情形最恰当的描述是:
 - 直接歧视
 - 间接歧视
 - 都不是, 因为宗教信仰已被移除
 - 违反了“四五规则”
- 以下哪一项是移除宗教信仰变量后差异仍然存在的正确原因?
 - 模型在移除宗教信仰后其实并未重新训练
 - 周末排班可接受度与休假申请这两项变量, 通过与宗教信仰的相关性, 依然携带着宗教信仰的影响
 - 该平台在法律上被要求直接使用宗教信仰变量

- (D) 无意识公平总是会提高预测准确性
- c. 假设该平台希望在排序算法中移除宗教信仰以外的另一项受保护属性。在同样的招聘情境下, 以下哪一变量最可能成为**年龄**的代理变量?
- (A) 就读大学
(B) 距申请人简历中第一份工作至今的年数
(C) 邮编
(D) 此前任职过的雇主数量
- d. 说明尽管你在 (c) 中所选的变量是一个代理变量, 它为何仍可能携带合理的预测信息。
- e. 假设该平台希望直接解决 (b) 中所指出的问题——移除宗教信仰后差异依然存在——而不是仅仅依赖无意识公平。请说明为何仅仅移除宗教信仰变量 (无意识公平) 本身并不足够, 并描述本章中一种可以解决该问题的替代方法。

问题二

某保险公司的自动化高风险标记系统, 会将保单转交人工核保复核。下表展示了两个群体各 100 份保单的结果。

	群体 A	群体 B
保单总数	100	100
真实发生高额理赔 ($Y = 1$)	30	10
被标记为高风险 ($\hat{Y} = 1$)	20	20
被标记且真实 $Y = 1$	15	8

- a. 计算各群体的标记比例 (被标记为高风险的份额)。群体 A: ____% 群体 B: ____%
- b. 根据 (a), 该示例中**人口统计学均等** (即 $\hat{Y} \perp X_P$, 各群体标记比例相同) 是否成立? 是 / 否
- c. 计算各群体的阳性预测值 (PPV), 即 $\Pr(Y = 1 | \hat{Y} = 1)$ 。群体 A: ____ 群体 B: ____
- d. 根据 (c), 该示例中**充分性** (各群体 PPV 相同) 是否成立? 是 / 否
- e. 计算各群体的真阳性率 (TPR), 即 $\Pr(\hat{Y} = 1 | Y = 1)$ 。群体 A: ____ 群体 B: ____
- f. 计算各群体的假阳性率 (FPR), 即 $\Pr(\hat{Y} = 1 | Y = 0)$ 。群体 A: ____ 群体 B: ____
- g. 根据 (e)-(f), 该示例中**分离性** (各群体 TPR 与 FPR 均相同) 是否成立? 是 / 否
- h. 出现这一模式的原因是:
- (A) 两个群体的真实基准率 ($Y = 1$ 的比例) 不同
(B) 模型整体校准性较差
(C) 样本量太小, 无法得出结论
(D) 人口统计学均等、分离性与充分性在数学上总是相容的
- i. 这对一名被要求“直接让模型公平”的从业者意味着什么?
- (A) 这是一项不可能完成、且没有可接受解决方案的任务
(B) 应满足哪一项准则是一个事先的政策决定, 仅凭更好的算法无法解决
(C) 模型只需要更多训练数据
(D) 只要提高预测准确性, 三项准则总能同时被满足
- j. 请说明为何在本例中人口统计学均等、分离性与充分性无法同时成立。

问题三

讲座介绍了五种模型设计:**M0**(完整模型, 直接使用受保护属性)、**MU**(无意识模型, 移除受保护属性)、**MDP**(通过预处理实现人口统计学均等性, 对全部非受保护预测变量去偏)、**MCDP**(条件人口统计学均等性, 仅对非合法预测变量去偏) 以及 **MC**(后处理, 在评分时对 M0 的预测结果按受保护属性取平均)。

- a. 请将下列每一种监管干预类型与最可能满足该要求的模型设计进行配对, 可选项为: M0、MU、MDP、MCDP、MC, 或“五种设计中的任意一种, 并配合所需的流程措施”。
- i. 禁止变量规则
 - ii. 代理性歧视规则
 - iii. 差异性影响或均等性规则
 - iv. 算法影响/透明度义务
- b. 以下哪一项是 MU 特有的主要局限性?
- (A) 无法应用于连续型结果变量
 - (B) 未能解决通过相关代理变量产生的间接歧视
 - (C) 需要在评分时重新识别受保护属性
 - (D) 在五种设计中总是产生最大的准确性损失
- c. 假设某银行的贷款审批模型使用收入、还款记录与邮编作为预测变量, 其中收入与还款记录在该司法辖区被视为合法的信用风险因素, 而邮编则不然。针对一项直接检验模型在各群体间结果的监管制度, 请说明在这一贷款情境下, 为何 MCDP 通常优于 MDP。

问题四

假设你是问题二至三中所所述保险公司的首席数据科学家, 该公司车险定价模型的受保护属性为性别。首席精算师要求你在车险定价模型上线之前, 结合问题二中所揭示的群体 A 与群体 B 之间的基准率差异, 就应采用公平性方案提出建议。

请撰写一份简短备忘录 (200–300 字), 内容需包括:

- a. 说明你建议在本定价情境中优先采用哪一项公平性准则 (例如人口统计学均等、条件人口统计学均等、充分性, 或本章介绍的其他准则), 并说明理由。
- b. 从五种模型设计 (M0、MU、MDP、MCDP、MC) 中推荐一种与该准则相符的设计, 并简要说明它是如何实现该准则的。
- c. 指出你所建议方案的一项局限性或权衡取舍, 提醒首席精算师在批准上线前应予以关注。

本题没有唯一正确答案。评分将关注你的回答是否清晰、内在逻辑一致地体现了对本章第一、二步内容的理解, 而不取决于你具体选择了哪一项准则或设计。