

作业: 公平性实践

负责任人工智能: 原则、治理与量化方法

黄斐, 新南威尔士大学

Table of contents

概述	1
说明	1
A 部分——车险定价	1
问题 1 — MDP 的 λ 扫描	1
问题 2 — 对另一个变量去偏	2
问题 3 — 为何仅靠无意识是不够的	2
问题 4 — 建议	2
B 部分——COMPAS 分类	2
问题 5 — 扩展 θ 扫描	2
问题 6 — 为何不存在满足所有准则的 θ	2

概述

这是一项实践性的 R 作业。它在第三章的两个案例研究基础上, 分别拓展到课堂讲义中未曾计算过的新情境, 随后要求你解读讲义中已有的结果。全作业分为两部分, 每部分对应一个案例研究, 各包含编程题与讨论题。

- A 部分——车险定价 (2 道编程题, 2 道讨论题)。
- B 部分——COMPAS 分类 (1 道编程题, 1 道讨论题)。

说明

请使用与第三章课堂讲义相同的数据集、软件包和预处理方式。请提交一份文档, 其中应包含你的代码、输出结果、图表, 以及书面回答。如果你愿意, 可以使用 Quarto 或 R Markdown 来完成这一点, 这样比较方便, 但只要文档包含以上全部内容, 采用任何格式均可接受。

本作业直接建立在第三章课堂讲义 (可在课程网站上获取) 的代码基础之上。请复用讲义中的数据加载步骤、辅助函数以及模型公式, 而非重新实现它们。

A 部分——车险定价

问题 1 — MDP 的 λ 扫描

第三章课堂讲义在构建 MDP 时, 调用 `make_di_removed_data()` 始终使用 $\lambda = 1$ (完全修正), 但 λ 是一个可调的旋钮, 而非开关, 正如 COMPAS 案例研究中 `roc_pivot(theta = ...)` 的 θ 一样。本题请你对这一旋钮进行扫描。 $\lambda = 0$ 精确等价于 MU (不对任何预测变量去偏), $\lambda = 1$ 精确等价于讲义中的 MDP (模型 3), 而介于两者之间的取值, 则是讲义从未计算过的部分修正版 MDP。

- 对 λ 取 $c(0, 0.25, 0.5, 0.75, 1)$ 中的每一个值, 将每一个预测变量都视为非合法变量并加以去偏, 重新拟合模型, 并报告差异性影响比率和 RMSE。

- b. 将你得到的五组 (λ , DIR, RMSE) 结果绘制成图, 例如分别绘制 DIR 与 RMSE 随 λ 变化的两条折线, 或绘制一张公平性—准确性散点图, 并在每个点上标注对应的 λ 值。
- c. 随着 λ 从 0 增大到 1, 是以准确性为代价换取公平性提升, 还是相反, 或者两者均未发生, 又或者是别的情形? 请用你自己的数字支持你的答案。不要在未加检验的情况下, 假定这里一定存在标准的公平性—准确性权衡关系。

问题 2 — 对另一个变量去偏

讲义中的 MCDP 设计仅对 `Insurancescore`(讲义视为唯一非合法变量) 去偏, 其余每一个合法预测变量都保持不变。本题请你将同样的模式应用于讲义从未去偏过的另一个变量。

- a. **实现方案。**简要说明你将如何在 $\lambda = 1$ 下仅对 `Density` 去偏, 保持 `Insurancescore` 及其余所有预测变量不变, 并重新拟合模型。
- b. **编程实现。**实现你的方案, 并按照问题 1 完全相同的方法, 计算差异性影响比率和 RMSE。
- c. **结果分析。**将这一结果与问题 1 中 $\lambda = 0$ 的结果 (等价于标准的 MU 设计, 完全不对任何预测变量去偏) 进行比较。仅对 `Density` 去偏, 是否明显改变了差异程度? 结合第二章的代理变量概念, 请提出一个原因, 说明为何对 `Density` 去偏的效果, 与讲义中对 `Insurancescore` 去偏 (MCDP) 的效果会有所不同。

问题 3 — 为何仅靠无意识是不够的

- a. 利用讲义中的平均保费表, 分别计算 M0 与 MU 的差异性影响比率 (DIR)。描述你观察到的规律。移除 `Gender` 是否使 DIR 更接近 1? 哪一方支付更多是否发生了变化?
- b. 结合第二章的代理性歧视概念, 解释这一规律出现的原因。

问题 4 — 建议

基于你在问题 1 和问题 2 中得到的结果, 你会建议部署不做任何去偏 (MU)、完全 MDP 式去偏 ($\lambda = 1$), 还是某个中间 λ 值的定价模型? 请通过指出你所推荐的设定最符合第二章中哪一项具体的公平性准则, 来论证你的选择, 并将其与你在问题 1 中发现的准确性代价 (或未发发现代价) 加以权衡。

B 部分——COMPAS 分类

问题 5 — 扩展 `theta` 扫描

讲义中的 `roc_pivot` 结果表止步于 $\theta = 0.20$ 。本题请你继续这一扫描。

- a. **实现方案。**简要说明你将如何在 $\theta = 0.25$ 与 $\theta = 0.30$ 下对 MU 模型应用 `roc_pivot()`, 并使用讲义中对 M0 与 MU 所用的同一套 `fairness` 包函数, 计算准确率、人口统计学均等性、TPR 差距与预测率均等性。
- b. **编程实现。**实现你的方案, 并报告这两个新 θ 取值下的四项指标。
- c. **结果分析。**讲义表格中的模式 (人口统计学均等性与 TPR 差距进一步超调至 1 以下、预测率均等性持续恶化、准确率不断下降), 在这些更高的 θ 取值下是否延续? 还是出现了性质不同的变化? 是否存在一个临界点, 超过该点后这一修正便不再有实际意义?

问题 6 — 为何不存在满足所有准则的 `theta`

课堂讲义中 COMPAS 的 `roc_pivot` 结果表, 报告了在多个 θ 取值下的人口统计学均等性、TPR 差距 (机会均等) 与预测率均等性。请运用第二章的不可能性结论, 解释为何不存在能够使这三项准则同时接近 1 的单一 θ 值。要使这样的 θ 存在, 两个群体之间需要满足什么条件?