

作业: 可解释性原则

负责任人工智能: 原则、治理与量化方法

黄斐, 新南威尔士大学

Table of contents

概述	1
说明	1
问题	1
问题 1——为何需要可解释性, 以及何时不需要	1
问题 2——利益相关方映射	1
问题 3——置换特征重要性 (PFI)	2
问题 4——PDP 的弱点, 及其重要性	2
问题 5——在 SHAP 与 LIME 之间取舍	2

概述

本作业旨在检验你对第 4 章所涵盖的概念与方法的理解: 可解释性、利益相关方需求, 以及本章深入介绍的三类事后解释方法 (PFI、PDP 及其 ICE/ALE 相关方法, 以及 SHAP 与 LIME 的比较)。该框架具有普遍适用性, 适用于任何具有重大影响的自动化决策——大多数问题要求你选择一个自己熟悉的领域 (例如保险承保与定价、信用评分、招聘筛选或临床风险模型); 请选定一个领域并在全篇中保持一致, 除非某一问题另有说明。

说明

请提交书面答案。

问题

问题 1——为何需要可解释性, 以及何时不需要

- 在你所选择的领域中, 分别描述一项明显需要可解释性的高风险决策, 以及同一领域中一项不需要可解释性的较低风险决策。二者的具体差异是什么?
- 讲义开篇的案例 (荷兰托育补贴算法) 说明了这样一种后果: 没有任何人, 无论是受影响的家庭、个案工作者还是法院, 能够获得模型输出背后清晰、可核查的原因说明。请选择一个公共福利管理之外的领域, 描述在该领域中类似的失败会是什么样子: 谁会无法获得解释, 又会造成什么危害?

问题 2——利益相关方映射

选择你所选领域中相关的三类利益相关方 (例如在保险中: 投保人、监管机构与内部模型验证人员; 在招聘中: 候选人、平等就业机会监管机构与招聘经理)。

- 针对每一位利益相关方, 指出适合的解释范围 (全局与局部) 及一种合适的方法, 并用一到两句话说明理由。
- 解释为何单一解释方法不太可能同时满足这三类利益相关方的需求。

问题 3——置换特征重要性 (PFI)

- a. 在你所选择的领域中, 描述一份 PFI 排序能够告诉一位正在审查新拟合模型的内部模型验证人员什么信息, 并说明为何这通常是对一个新模型运行的第一项诊断。
- b. PFI 通过逐一打乱单个特征来衡量其重要性。请描述你所选领域中涉及两个相关预测变量的场景, 并解释为何单独打乱其中一个变量可能产生具有误导性的重要性分数。

问题 4——PDP 的弱点, 及其重要性

- a. 讲义中的对抗性案例研究 (Xin, Hooker & Huang, 2025) 在不改变底层模型的情况下, 使一个具有歧视性的模型的 PD 图看起来趋于平坦。请用自己的话, 指出使这一操纵成为可能的 PDP 的两项具体弱点, 并解释每一项弱点是如何被利用的。
- b. 选择保险之外的一个领域。描述一个场景, 在该场景中某个特征的效应在不同子群体间确实存在差异, 解释在此情形下单独使用 PDP 为何可能具有误导性, 以及叠加 ICE 曲线如何能够揭示 PDP 所掩盖的信息。

问题 5——在 SHAP 与 LIME 之间取舍

- a. 一个组织需要在“解释权”要求下, 向监管机构证明某一项不利决策 (例如拒保、拒贷或拒绝某求职者) 的合理性。你会建议使用 SHAP 还是 LIME? 为什么?
- b. 如果该组织改用另一种方法, 你会指出什么具体风险?