

作业 4：可解释性原则

《负责任人工智能：原则、治理与量化方法》

黄斐，新南威尔士大学

姓名：林富强 专业：软件工程

所选应用场景

延续第一次作业的场景：**软件缺陷预测系统**——一家软件公司构建机器学习模型，根据代码仓库的提交记录、代码度量（如代码行数、圈复杂度）、历史缺陷数据以及开发者的行为特征，预测某次代码变更或某个模块在未来出现缺陷的概率，并据此决定哪些变更需要额外的人工评审、加长测试或推迟发布。全篇各题均以该场景作答，并在不同题目中适当切换视角（内部验证人员、工程负责人、开发者、审计方）。

问题一：为何需要可解释性，以及何时不需要

a. 高风险决策与低风险决策的对比

高风险决策——对即将合入主分支的代码变更实施“发布门禁”（**release gate**）。模型将某次变更标记为“高缺陷风险”，从而触发强制人工评审、加长回归测试并推迟发布。这是一项高风险决策，理由有三：

后果严重且不对称：若漏检（模型未标记、但变更确实引入缺陷），缺陷流入生产环境，可能导致线上故障、数据损坏乃至安全事故，修复成本远高于发布前拦截；若误报（标记了实际无缺陷的变更），则无谓地阻塞发布、消耗团队评审与测试资源。

决策不可逆、影响面广：发布是一次性事件，一旦合入并上线，影响的是全体用户以及后续所有基于该代码库的开发工作，无法低成本撤销。

存在签字责任与事后审计：工程负责人（QA 经理）须为发布决策负责；一旦事后出现生产事故，组织内部审计或外部监管会追问“当时为何放行/拦截”，模型输出必须能够被解释和复核。

低风险决策——对内部工具代码的“建议重构”提示。例如模型对一段仅供内部使用的脚本或非关键路径的辅助函数，提示“建议重构以降低圈复杂度”，或对纯文档类变更自动给出“低风险”标签。它不需要可解释性，因为：

后果轻微且可逆：重构建议即使错误，开发者可自行忽略，最坏情况只是浪费几分钟查看；标签错误不影响任何用户，也没有不可逆后果。

有充分的人工兜底：内部工具代码本身由开发者直接审查，模型建议只是辅助，最终判断权在人，错误容易发现和纠正，不涉及发布放行、不涉及任何人的权益。

二者的具体差异：其一是**后果的严重性与不对称性**——发布门禁的漏检/误报都会产生显著代价，重构建议的错误近乎零成本；其二是**可逆性**——发布决策不可逆，重构建议随时可改；其三是**责任与审计**——是否有人需要为决策签字、是否会被事后审查；其四是**利益相关方的解释权**——发布门禁影响开发者的工作安排，需要申诉与复核渠道，而重构建议只影响提出建议的开发者本人。差异的根源正是讲义所述的判断标准：应用风险越低、方法越成熟、越有充分的人工兜底，追求可解释性的理由就越弱。

b. 类似“托育补贴丑闻”的失败（公共福利管理之外）

在软件缺陷预测场景中，如果模型对“哪些开发者容易产出缺陷代码”给出高风险标记（例如把“深夜提交占比”作为强特征），却没有任何人能够获得关于“为什么被标记”的清晰、可核查的说明，就会出现与荷兰托育补贴丑闻同构的失败：

谁会无法获得解释：被标记为“高缺陷风险作者”的开发者本人；为其做绩效、排班与任务分配决策的团队负责人；以及负责复核标记是否合理的人力资源或质量审计人员。三者都无法真正审视模型的推理过程。

个体层面的危害：开发者反复收到高风险标记却不知道原因，无法针对性改进（究竟是圈复杂度过高、测试覆盖不足，还是仅仅因为提交时间晚？），改进努力落空；若这些标记被关联到绩效评估、晋升或任务分配，就会在无人能解释的情况下长期影响其职业发展，形成事实上的不公正对待。

组织层面的危害：工程负责人无法区分“真实的代码质量问题”与“模型学到的代理模式（如深夜提交≈加班≈某种人口特征）”，系统沦为黑箱；由于无法解释，也就无法申诉、无法修正，模型的错误信号持续误导资源分配，质量改进动作失效。

治理层面的危害：一旦开发者或团队就标记结果发起质疑，公司无法提供可核查的说明，就会面临内部信任崩塌与外部合规风险（如《个人信息保护法》第 24 条的解释权、EU AI Act 对高风险就业相关系统的要求），最终不得不由更高层介入叫停系统。

关键教训与托育丑闻一致：**没有任何一名负责人单独决定这样做**——是模型输出与人类理解、质疑能力之间的鸿沟，让系统性错误在无人负责、无人能够复核的状态下持续运行，直至酿成重大后果。

问题二：利益相关方映射

在本场景中选取三类利益相关方：**内部模型验证人员**（数据科学家/机器学习工程师）、**工程负责人**（QA/发布经理，为决策签字审批的运营方）、**被评估的开发者**（决策对象与数据主体）。

a. 每位利益相关方所需的解释

利益相关方	解释范围	合适方法	理由
内部模型验证人员	全局 + 局部	PFI（全局特征重要性排序）；SHAP 摘要图/依赖图	需要在拟合后整体判断模型依赖哪些信号、是否混入代理特征，并用单例分解核实预测是否符合领域知识。
工程负责人（QA/发布经理）	局部	SHAP 瀑布图	为单个变更的发布放行决策签字，需要理解“为什么这个模块被标记为高风险”，瀑布图给出基准值加各特征推拉力的完整分解。
被评估的开发者	局部、通俗语言	反事实解释，或精炼后的局部归因	需要知道“为什么我的变更被标记”以便改进；技术性 Shapley 值不适合直接展示，应给出简短、可行动、可申诉的通俗说明。

b. 为何单一解释方法难以同时满足三类需求

范围与粒度冲突：验证人员需要全局视图（模型总体依赖哪些特征），工程负责人与开发者需要局部视图（为什么是这一次预测）。

技术程度冲突：验证人员需要完整、精确的归因（Shapley 值、依赖图），开发者需要简短、通俗、可行动的理由——同一种输出形式无法同时满足两类受众。

忠实性与稳定性要求冲突：签字与审计场景要求解释稳定且忠实于模型（有公理化保证、可复现），面向开发者的沟通更看重简洁性与可理解性，甚至允许采用近似或反事实陈述。

用途与媒介不同：内部仪表盘上的技术图、监管文档中的群体层面分析、面向个人的通知/申诉说明，三者对应的解释形态各不相同。

结论：解释是按“为谁、关于什么、出于什么目的”三元组匹配的——先确定要回答的问题，再匹配范围（全局/局部）与受众（技术/通俗）。单一方法只能覆盖一个“范围×受众×用途”组合，因此实际系统需要组合使用：PFI 与 PDP 做全局诊断，SHAP 做局部归因，反事实解释做面向开发者的沟通，彼此互补。

问题三：置换特征重要性（PFI）

a. PFI 排序告诉验证人员什么，为何是第一项诊断

一份 PFI 排序能够同时呈现两类信号。其一，模型实际依赖哪些合法信号：例如圈复杂度、测试覆盖率、历史缺陷密度等特征重要性高，符合领域知识，说明模型在按预期工作；其二，是否存

在非预期或代理特征：若“开发者 ID”“提交时段”“目录路径”等特征的重要性异常突出，说明模型学到了与人员/团队相关的模式，提示需要进行公平性审查——这与讲义中车险 PFI 案例揭示“InsuranceScore 贡献显著”的逻辑完全一致。此外，特征重要性与领域知识明显不符时，往往是数据质量问题的线索（特征噪声、标签泄漏或训练-测试分布漂移）。

它通常是对新模型运行的第一项诊断，因为：PFI 模型无关、无需重新训练、实现成本低，几行代码即可把黑箱压缩为一份全局排序；它回答的是上线前最关键的问题——“模型到底在用哪些信号？”——从而第一时间暴露代理变量、非预期依赖与数据质量问题，为后续一切深入分析（PDP、SHAP、公平性审计）指明方向。在软件缺陷预测中，如果该模型用于发布门禁，验证人员会优先用 PFI 确认“代码质量类特征”确实主导预测，而非“谁提交的代码”。

b. 相关预测变量场景：为何单独打乱会产生误导

场景：特征“代码行数（LOC）”与“圈复杂度”高度相关——一个模块的行数越多，其分支结构与圈复杂度往往也越高，二者同为代码规模/复杂度的度量，现实中几乎必然正相关。

PFI 打乱某列时隐含假设该列与其他列独立，但 LOC 与圈复杂度并不独立。单独打乱 LOC 后，数据中会出现大量现实中几乎不存在的组合（例如“超大代码量+极低圈复杂度”，或“极小代码量+极高复杂度”），模型在这些不现实的组合上评分会显著劣化。于是：

若模型真正依赖的是圈复杂度，打乱 LOC 造成的误差上升，主要来自“生成了不现实组合”而非“模型独立依赖 LOC”，LOC 的重要性分数被**高估**，成为打乱操作本身的产物；

反过来，打乱 LOC 时模型仍可部分依靠未被打乱的圈复杂度维持表现，LOC 的真实边际贡献可能被**低估**。

无论哪个方向，单独打乱一个相关变量得到的分数，反映的都是“打乱操作与相关结构的相互作用”，而非该特征的真实边际贡献——这正是讲义所指出的“重要性分数可能只是打乱操作的产物”。因此，解释 PFI 时必须先检查特征相关性，必要时对相关特征组整体打乱（组置换），并注意 PFI 只能回答“是否重要”，不能回答“如何、朝哪个方向、在什么范围内影响预测”。

问题四：PDP 的弱点，及其重要性

a. 使对抗性操纵成为可能的 PDP 两项弱点

弱点一：独立性假设导致的边际外推。 PDP 构造时对除目标特征外的所有特征取边际平均，隐含假设特征相互独立。当目标特征与其他特征相关时，把目标特征固定为某一值、再遍历其余特征，会产生大量在真实数据中从未或极少出现的组合——这些**稀疏外推区域**正是 PDP 计算所依赖的部分。**攻击者如何利用：**在数据真实、密集出现的区域保持模型输出不变（现实中的预测几乎不受影响），仅在稀疏外推区域把输出替换为“看似不具歧视性”的值；由于 PDP 是对这些区域的平均，曲线被拉平，而底层模型在现实中的歧视行为被完整保留（保真准确率超过 95%）。

弱点二：取平均掩盖异质性。 PDP 是全体样本的平均效应，个体或子群体之间方向相反的效应会在平均中相互抵消——平均值可能平坦或很弱，即使没有任何一个个体真正经历过这个“平均效应”。**攻击者如何利用：**审查者习惯把“受保护属性的 PD 图平坦”当作模型公平的证据，攻击者正是利用这一平均性质制造虚假的平坦曲线，使审查者误判；即使不进行对抗攻击，真实的子群体差异也会被平均掩盖，令 PDP 失去诊断价值。

结论：一张平坦的 PD 图只是公平性审查的“输入”，而非“证明”。应结合 ICE 曲线、特征相关性检查与 ALE 图交叉验证，并警惕任何单独依赖 PDP 的公平性结论。

b. 保险之外的场景：子群体效应差异与 ICE 的作用

场景（软件缺陷预测，公共福利与保险之外）：特征“代码变更规模（LOC）”对不同子群体的效应方向相反——按模块类型划分：在**新开发模块**中，LOC 越大缺陷概率上升越快（新代码缺乏历史验证，规模越大风险越高）；而在**长期维护模块**中，LOC 的增加往往来自重构或补丁，缺陷率可能不升反降。即同一特征在两个子群体中对预测结果的影响方向相反。

单独使用 PDP 的误导性：PDP 把两个子群体的曲线平均，两条方向相反的曲线在平均后可能接近平坦或仅呈弱效应，看起来“变更规模对缺陷风险几乎无影响”。但这不代表任何真实个体经历过该平均效应——模型实际对新模块的大规模变更是强正向、对维护模块是弱负向的。若验证人员据此做特征取舍或风险分级，会错误低估新模块大规模变更的缺陷风险，甚至误删有用特征。

叠加 ICE 曲线能揭示什么：ICE 为每个观测样本画一条“保持其他特征不变、预测随 LOC 变化”的曲线，PDP 正是所有 ICE 曲线的平均。把 ICE 叠加在 PDP 之上，可以清楚看到**两个方向相反的曲线簇**——新模块的 ICE 普遍陡峭上升、维护模块的 ICE 平坦或下降，而 PDP 的平均线正是把这两个簇抵消后的结果。审查者据此识别异质性，进而按子群体分别建模或分群评估风险，而不是信任单条平均曲线。

问题五：在 SHAP 与 LIME 之间取舍

a. 解释权下向监管机构证明不利决策的合理性：建议 SHAP

我会建议使用 SHAP（若模型为梯度提升/树集成，则具体使用 TreeSHAP）。理由针对“解释权”场景下“向监管机构证明不利决策合理性”这一用途：

忠实性有公理化保证：SHAP 满足局部准确性（各贡献之和恰好等于预测与基准之差）、一致性与缺失一致性，解释与模型真实行严格对应——监管机构要求的是“可核查的说明”，而非“听起来合理的说明”。

稳定性与可复现性：TreeSHAP 对树模型是精确解，无随机性、结果可复现；监管质询时任何两次审计得到同一答案，可以逐项核对数值。

可加性与可汇总性：单个不利决策（如某次变更被拒发）可用瀑布图分解为“基准值+各特征贡献”，局部值还可汇总为全局重要性，支撑从个案到整体的完整证据链。

计算高效：TreeSHAP 以多项式级时间复杂度精确计算，可随时为任意个案生成解释，适合生产环境中基于树的模型（XGBoost、LightGBM）。

在软件缺陷预测中：某次变更被标记为高风险而拒发，可用瀑布图向监管/审计方展示“该变更的缺陷风险预测=基准值+圈复杂度贡献+变更规模贡献+历史缺陷贡献……”，每一步都有数值依据、可复核、可申诉。

b. 若改用 LIME，需要指出的具体风险

不稳定性：LIME 的结果对邻域核宽度等超参数高度敏感，两次运行可能给出不同解释——监管审计无法接受“答案随参数浮动”的证据，解释不可复现即不可核查。

无公理化保证、可能不忠实：LIME 是局部代理近似，不承诺忠实于模型，存在“解释听起来合理但未反映模型真实推理”的风险——这恰是解释权要杜绝的误导性说明（Rudin 2019 的不忠实代理模型教训：看起来令人信服的解释，可能是代理模型的产物，而非黑箱本身）。

扰动不相关性与外推：LIME 的扰动样本不考虑特征相关性，会生成现实不存在的组合，局部线性模型可能在这些区域拟合出与实际决策无关的系数。

可对抗操纵：与 SHAP 一样可能被刻意构造以掩盖偏见（Slack 等 2020），但因缺乏一致性约束，LIME 更容易被设计成看似合理、实则掩盖歧视行为的解释。

结论：LIME 适合快速探索与非树模型的原型阶段；但在“解释权/监管举证”场景中，其不稳定与不忠实的特性使每条解释都可能在质询中被推翻，因此不推荐作为向监管机构证明决策合理性的工具。

小结

本作业以软件缺陷预测系统为场景，将可解释性的概念框架应用于实际决策：高风险决策（发布门禁）需要可解释性而低风险决策（重构建议）不需要；三类利益相关方需要不同范围、不同技术程度、不同用途的解释，单一方法无法同时满足；PFI 作为第一项诊断暴露模型依赖的信号与代理特征，但在相关特征下会产生误导性分数；PDP 的外推与取平均两项弱点可被对抗性利用，平坦的 PD 图不能作为公平性证明，ICE/ALE 是必要的补充；而在解释权与监管举证场景中，SHAP（TreeSHAP）凭借公理化保证、稳定性与可复现性优于 LIME。可解释性本身不是目的，而是实现问责、信任与治理的手段。