

作业: 可解释性实践

负责任人工智能: 原则、治理与量化方法

黄斐, 新南威尔士大学

Table of contents

概述	1
说明	1
问题	1
问题 1 — 针对新变量的 PDP 与 ALE	1
问题 2 — SHAP 解释	1
问题 3 — 批判性评估这一工具箱	2

概述

这是一项动手实践的 Python 作业, 延伸自第 5 章的保险可解释性案例研究, 应用该章介绍的通用可解释性工作流程 (全局重要性 → 主效应 → 局部解释)。请在整个作业中复用讲座已经拟合好的频率模型, 以及讲座自身的数据准备与辅助函数 (`compute_pdp`、`compute_ale`、`group_feature_name`、置换重要性、TreeSHAP)。你的任务是把这些方法应用到讲座尚未分析过的变量与保单上, 并对结果加以解释, 而不是重新推导这些底层代码。

说明

请使用与第 5 章讲座相同的数据集、模型与辅助函数 (Case Study/pg15training.csv, 以及讲座自身的 `freq_model` 与各解释函数)。提交你的代码、图表和书面回答。在题目允许你自行选择变量或保单的情形下, 请优先选择讲座尚未详细分析过的变量或保单 (而非默认使用 Age 和 Bonus, 或讲座自身所用的示例保单); 你的得分来自诊断与解释本身, 而不是重新运行讲座已经运行过的代码。

问题

问题 1 — 针对新变量的 PDP 与 ALE

选择一个讲座尚未详细分析过的变量 (例如 Density 或 Value)。

- 复用讲座的 `compute_pdp/compute_ale` 函数, 为该变量绘制 PDP 图和 ALE 图。
- 比较 PDP 曲线与 ALE 曲线。如果二者在某一区域出现明显分歧, 请结合数据的相关结构以及该区域的数据支撑量, 解释分歧产生的原因。如果二者高度吻合, 请说明这一现象反映出该变量与其他预测变量的相关性有多弱, 并解释在这种情况下 PDP 为何仍然是该效应的合理概括。

问题 2 — SHAP 解释

- 计算全局 SHAP 值。找出除 Age 和 Bonus 之外影响最大的两个特征, 并描述其效应方向。
- 从测试集中选择一份保单 (不要使用讲座自身的示例保单), 针对其预测结果绘制局部 SHAP 瀑布图。

- c. 用 3—4 句话解释该保单预测索赔频率的原因, 措辞方式应如同你在向一位询问“为什么这份保单会得到这样的风险评估结果”的客户解释一样(避免使用诸如“SHAP 值”“边际贡献”之类的技术术语; 由于该模型预测的是索赔频率而非保费, 请以预测的索赔率/风险水平来表述你的解释, 而不是保费本身)。

问题 3 — 批判性评估这一工具箱

该模型可能被用于承保决策, 并受到“解释权”要求(第 1 章和第 4 章讨论过)的约束。

- a. 针对这一用途, 批判性地评估 PFI、PDP、ALE 与 SHAP 这四种方法。对每一种方法, 分别指出一项真正的优势与一项真正的局限, 并结合你以上的结果, 以及讲座中对你未亲自计算过的方法所给出的发现。
- b. 基于你的评估, 说明这些方法在向监管机构说明单一不利决策时应如何相互配合, 而不是主张其中某一种方法本身就已足够。