

作业: 隐私实践

负责任人工智能: 原则、治理与量化方法

黄斐, 新南威尔士大学

Table of contents

概述	1
说明	1
问题 1——移除 AgeGroup 后评估重新识别风险并应用 k-匿名性	1
问题 2——针对 66 岁以上、居住于密集城区的保单持有人运行差分隐私	2
问题 3——合成数据: 用于预测 Gender 的 TSTR	2

概述

这是一项动手实践的 R 作业, 在第七章保险案例研究的基础上, 将课堂讲义所介绍的“风险评估到隐私增强技术 (PET)”工作流程, 应用到讲义尚未计算过的具体参数选择上。你将在移除 AgeGroup 后评估重新识别风险, 并对这一缩减后的准标识符集合应用 $k = 100$ 的 k-匿名性, 针对一个指定的子群体运行差分隐私扫描, 并将合成数据的 TSTR 评估拓展到一个指定的替代模型。

说明

请使用与第七章课堂讲义相同的数据集和预处理方式。请提交一份文档, 其中应包含你的代码、输出结果、图表, 以及书面回答。如果你愿意, 可以使用 Quarto 或 R Markdown 来完成这一点, 这样比较方便, 但只要文档包含以上全部内容, 采用任何格式均可接受。

本作业直接建立在第七章课堂讲义 (可在课程网站上获取) 的代码基础之上。请复用讲义中的数据加载步骤 (data/pg15training_raw.csv、df_raw)、准标识符分组、createSdcObj() 的设置、差分隐私辅助函数 (laplace_noise、dp_mean、dp_proportion), 以及合成数据相关对象 (df_synth_input、syn_df、df_real_holdout、model_real、model_syn), 而非重新实现它们。

问题 1——移除 AgeGroup 后评估重新识别风险并应用 k-匿名性

讲义使用五个准标识符 (Gender、AgeGroup、DensityGroup、ValueGroup、BonusGroup) 计算风险, 得到全局风险为 0.77%, 有 102 条记录的等价类规模不超过 5。随后, 讲义对这一五变量集合在 $k = 50$ 下应用 localSuppression() (大于教科书式的最小值 $k = 5$, 因为 $k = 5$ 在该数据集上几乎没有产生任何可见的抑制), BonusGroup 被抑制 6.9%, ValueGroup 被抑制 0.44%, 全局风险降至 0.41%。讲义自己的准标识符表格将 Age(或 AgeGroup) 描述为“最具识别性的变量之一”。

- 从准标识符集合中移除 AgeGroup, 按照讲义的做法使用 createSdcObj(), 并将 keyVars 设为 c("Gender", "DensityGroup", "ValueGroup", "BonusGroup"), 重新计算全局风险, 以及 $k \leq 5$ 的记录数。
- 将其与讲义中五变量的基准结果进行比较。移除 AgeGroup 后, 风险是上升还是下降? 这一变化的幅度, 是否与讲义中“AgeGroup 是最具识别性的变量之一”这一说法相符?

- c. 在这一相同的四变量准标识符集合上, 保持与讲义相同的 Gender $\rightarrow$ BonusGroup 顺序, 设置 `importance = c(1, 2, 3, 4)`, 在 $k = 100$ 下应用 `localSuppression()`。按照讲义表格的样式, 报告每个准标识符的抑制率, 以及最终的全局风险。
- d. 将这一结果与讲义 $k = 50$ 、五变量的结果进行比较。抑制是否仍然集中在讲义所发现的同一个变量上, 还是扩散到了更多变量? 请结合 `importance` 排序解释原因, 并说明预先移除 `AgeGroup` 是否会改变这一比较。

问题 2——针对 66 岁以上、居住于密集城区的保单持有人运行差分隐私

讲义比较了整个 100,000 条记录的业务组合 (即便在 $\varepsilon = 0.1$ 时噪声也可忽略不计) 与一个 487 条记录的子群体 (男性、66 岁以上、豪华车, 同样的 `epsilon` 取值会产生数年之差的噪声)。

- a. 将 `df_raw` 筛选为 `AgeGroup == "66+"` 且 `DensityGroup == "Dense urban"` 的子群体, 对该子群体的 `Age` 变量, 在讲义的五个 `epsilon` 取值下运行相同的 `dp_mean` 扫描。
- b. 报告该子群体的规模 n , 以及其在不同 `epsilon` 下的噪声模式 (如讲义所示的表格或重复抽样箱型图)。
- c. 相对于讲义中的两个基准群体 ($n = 100,000$ 与 $n = 487$), 你观察到的噪声量, 是否大致符合敏感度公式 $(\text{upper} - \text{lower}) / n$ 的预测? 请用该子群体的 n 定量论证你的答案。

问题 3——合成数据: 用于预测 Gender 的 TSTR

讲义的 TSTR (以合成数据训练、以真实数据检验) 检验, 比较了一个在真实数据上训练的理赔频率模型与一个在合成数据上训练的模型, 二者都在合成过程从未见过的 2,000 条真实留出记录上以 AUC 评估, 得到的差距可忽略不计 (0.728 对 0.729)。

- a. 拟合一个逻辑回归, 使用 `Age`、`log1p(Density)`、`log1p(Value)` 和 `Bonus` 预测 `Gender`, 分别在 `df_synth_input` 和 `syn_df` 上各训练一次。请直接复用讲义构建好的 `df_synth_input`、`syn_df` 和 `df_real_holdout`, 只改变模型公式与预测目标本身。
- b. 使用讲义中的 `auc_manual()` 函数, 报告真实数据训练模型与合成数据训练模型在真实留出集上各自的 AUC。
- c. 首先, 将两个 AUC 与 0.5 (一个完全没有真实预测能力的模型应得到的值) 进行比较: `Age`、`Density`、`Value` 和 `Bonus`, 无论是在真实数据训练模型还是合成数据训练模型上, 对 `Gender` 究竟有多强的预测能力? 然后, 将两个 AUC 之间的差距, 与讲义中接近于零的差距进行比较。这个差距是否更大? 你在第一步得到的答案, 是否改变了这一差距的含义, 或它应引起你多大程度的担忧? 如果差距更大, 请结合 `synthpop` 的 CART 方法生成各变量的方式, 提出一个理由, 说明为什么合成数据在这里可能比在预测理赔频率上表现得更吃力。