

作业: 权衡、整合与治理

量化负责任人工智能: 原则、治理与方法

黄斐, 新南威尔士大学

Table of contents

概述	1
说明	1
问题	1
问题一——生命周期案例研究与技术选择	1
问题二——公平性与可解释性的相互作用	2
问题三——治理文档设计	2
问题四——总结性反思	2

概述

本毕业设计作业要求你将本课程中关于公平性、可解释性和隐私的内容整合到一个统一的案例研究中, 并对负责任人工智能工具箱的权衡与局限性进行批判性反思。该框架具有普适性——请自行选择一个领域 (保险、信贷、招聘、医疗保健, 或其他你选择的领域), 并在整个作业中保持一致地使用该领域。

说明

你可以沿用在第一章作业中定义的应用场景, 也可以重新定义一个——请明确说明你的选择, 并在以下全部四道题中保持一致地使用该场景。

本作业没有固定字数限制。请按每道题的具体要求作答, 篇幅长短视需要而定。几句论证清晰的话, 胜过一篇内容空泛却篇幅冗长的答案。作为整合全课程内容的毕业设计作业, 预计总用时约两至三小时。

请用让不同领域背景的同学也能读懂的方式作答, 即便他们对你所选应用场景的领域毫无了解。如果使用了你所在领域特有的术语, 请在首次出现时用通俗语言简要解释。

问题

问题一——生命周期案例研究与技术选择

请在你选择的领域中选定一个全新的人工智能驱动产品或决策系统——例如, 保险领域的人工智能辅助理赔分诊系统或动态定价引擎; 信贷领域的自动信用评分或贷款审批模型; 招聘领域的简历筛选或面试评分工具; 或医疗保健领域的诊断辅助或分诊工具。你可以沿用第一章作业中的应用场景。

针对以下六个生命周期阶段 (问题定义、数据收集、模型开发、模型验证、部署、监测) 中的每一个阶段:

- 指出该阶段涉及公平性、可解释性和隐私中的哪些考量因素 (可能不止一项适用)。
- 指出你将在该阶段部署的一项来自第 2–7 章的具体技术 (例如 MCDP 去偏、SHAP 局部解释、k-匿名化), 并简要说明选择理由。

然后, 选取其中一个阶段:

- c. 说明为什么“显而易见”的技术选择（例如始终使用 SHAP 进行可解释性分析，或始终使用差分隐私来保护隐私）在此情境下其实并不适用，并提出一个更合适的替代方案，结合该情境的具体约束条件（例如受众、数据量、监管要求、计算成本）论证其合理性。

问题二——公平性与可解释性的相互作用

本讲座除了讨论较为常见的公平性-准确性权衡与隐私-效用权衡之外，还指出了可解释性与公平性之间的相互作用。请运用你自己的推理，说明对模型输入实施诸如 MCDP 式去偏（第 2-3 章）之类的公平性干预措施，会如何改变客户随后获得的基于 SHAP 的解释（第 4-5 章）。然后用一个具体例子说明，你认为这是一种真实且不可避免的张力，还是可以通过治理或沟通方面的选择加以管理。

问题三——治理文档设计

请为问题一中产品的部署所需配套的模型治理文档草拟一份大纲。

- a. 列出 4-6 个该文档将包含的章节标题，并为每个标题用一句话描述其内容。
- b. 从中选取两个章节，分别说明它们主要对应第一章中的问责制原则还是可争议性原则，并解释原因。

问题四——总结性反思

本讲座明确指出，本课程“无法”做到某些事情（例如，无法解决所有价值权衡问题、无法保证符合监管要求、也无法替代组织治理——请参见讲座中所述的具体局限性）。

- a. 选取讲座中所述的一项局限性，并简要描述对问题一中你所选模型负责的领域专业人员（例如精算师、信用风险分析师、人力资源分析主管、临床决策支持负责人）在实践中切实弥合这一差距还需要哪些额外的知识、技能或组织能力（超出本课程范围）。
- b. 反思：在你自己未来的实践中，公平性、可解释性、隐私这三大支柱中，你预计哪一项影响最为深远，为什么。